

RAA MATEMÁTICAS APLICADAS A LA IA Y AL DEEP LEARNING

PARTE 1


Selecciona tres variables candidatas para el modelo multivariado.

Justificar tu elección con base en correlaciones, relaciones causales esperadas, y/o fundamentos estadísticos.

Las tres variables candidatas para el modelo multivariado son la temperatura media, el consumo histórico y el desempleo.

Para saber qué variables son las más adecuadas para trabajar con nuestro modelo, se han calculado tres maneras diferentes de ver cuáles son las que tienen una mayor correlación con la demanda de energía.

La primera ha sido crear un gráfico de correlaciones entre todas las variables, para ver si podemos sacar alguna primera hipótesis sobre los gráficos de manera visual. Gracias a los gráficos vemos que hay 2 variables que tienen cierta correlación con la demanda de energía, que son: el consumo histórico y la temperatura media. Para la tercera en el gráfico no se acaba de ver muy definido, por lo que decidimos crear una matriz de correlación para confirmar lo que hemos observado en el gráfico y poder sacar la tercera variable:



Gracias a la matriz de correlación (recordar que cómo más se acerque el valor de correlación a 0, menos correlación tiene) podemos confirmar nuestra primera hipótesis, ya que la temperatura media y el consumo histórico son las dos variables con más correlación con la demanda de energía. Seguidamente viene el desempleo y el gasto consumidos. Las dos tienen valores muy parecidos, pero escogemos desempleo ya que tiene un poco más de correlación.

Otra manera para detectar cuales son las variables que tienen más influencia respecto la demanda de energía, es crear una regresión lineal con todas las variables. En una regresión lineal, los coeficientes indican la importancia de cada variable.

Obtenemos los siguientes resultados:

	variable	coeficiente
0	temperatura_media	-483.982740
1	gasto_consumidor	153.932380
2	inflacion	-39.664755
3	desempleo	-142.893447
4	consumo_historico	403.145295

Los coeficientes de temperatura_media y de consumo_historica vuelven a confirmar nuestra hipótesis. Pero observamos que el coeficiente de gasto_consumidor es de 154 aprox y el de desempleo -143 aprox. Aunque ahora con la regresión lineal uno indica una mayor importancia que el otro, puede pasar. La correlación y los coeficientes de regresión miden cosas diferentes y no los podemos comparar directamente.

La variable más correlacionada la vamos a saber a partir de la matriz de correlación, mientras que con la regresión lineal vemos las que son más influyentes.

En nuestro caso, seleccionamos el desempleo frente al gasto_consumidor, ya que presenta una mayor correlación absoluta con la demanda energética y es más adecuada para una modelo de predicción.

Explica cómo estas variables se relacionan con el contexto empresarial (energía, consumo, economía).

Temperatura media (°C): El consumo aumenta en los extremos de temperatura. Si tenemos temperaturas muy bajas, tendremos un mayor uso de la calefacción eléctrica, mientras que si tenemos temperaturas altas tendremos un mayor uso del aire acondicionado. La temperatura media nos va a permitir prever altos picos de demanda y evitar posibles sobrecostes.

Consumo histórico (kWh): Nos indica la línea base histórica que han seguido los clientes. Gracias a esta variable podemos identificar estacionalidad (verano / invierno) y posibles comportamientos cíclicos (días laborales o festivos).

Desempleo (%): Es un indicador de riesgo de impagos. Un aumento de desempleo se puede traducir en que va a haber más gente en casa durante el día, pero también hay que tener en cuenta que puede producir un mayor riesgo a nivel de impagos, concepto vital para la planificación financiera.

Gasto del Consumidor (euros/mes): Define cuánto gasta cada cliente. Si el gasto en otros mercados sube, el consumidor puede tender a un recorte de uso energético o usarla de una forma más eficiente. Es un indicador importante si queremos predecir la tasa de abandono.

Inflación(%): La inflación afecta tanto a la empresa como al usuario. Una inflación alta suele reducir del consumo libre. En el modelo, puede ayudar a entender si un aumento en la facturación es por consumo real o por un ajuste de precios causado por la inflación.

PARTE 2

Realizar dos modelos y justificar cual es mejor usando alguna herramienta matemática para ello.

Los dos modelos que hemos escogido han sido la regresión lineal y un modelo polinómico de grado 2.

Para comparar los modelos nos vamos a fijar en diferentes métricas matemáticas, cómo el R^2 , RMSE, AIC y BIC.

	Regresión lineal	Polinómico grado 2
R^2	0.9186782630062839	0.923207968137096
RMSE	217.40978076108007	211.2680551208012
AIC	1542.924368132026	1545.1812489922925
BIC	1555.467561880227	1576.5392333627951

R^2 : El modelo polinómico de grado 2 explica un mayor porcentaje (92,3%) de la variabilidad de la demanda que el de regresión lineal (91,9%). Aunque hay que tener en cuenta que la diferencia entre ambos es mínima-

RMSE: El error medio sigue la misma tendencia que el R^2 . Es mayor en la regresión lineal, por lo que indica una mayor precisión predictiva para el polinómico, pero la diferencia es muy pequeña.

AIC y BIC: El modelo de regresión lineal tiene un menor AIC y BIC, por lo que nos indica que el modelo se va a ajustar mejor. El AIC más bajo nos aporta un mejor equilibrio entre ajuste y complejidad. El BIC penaliza más la complejidad.

El modelo polinómico de grado dos apenas mejora la capacidad predictiva ya que tiene una ganancia respecto al de regresión lineal muy pequeña.

Cómo los dos modelos tienen un rendimiento similar, vamos a escoger el modelo de regresión lineal, ya que es más simple, más interpretable, menos propenso al sobreajuste y generaliza mejor.

¿Crees que es necesario regularizar el modelo seleccionado?

Para saber si es necesario regularizar el modelo seleccionado, vamos a calcular las métricas R^2 , RMSE para el modelo de regresión lineal con y sin regularización, y lo mismo para el polinómico.

Obtenemos los siguientes resultados:

Modelo	R^2	RMSE
Regresión lineal	0,8290	265,48
Polinómica grado 2	0,8193	273,48
Ridge Regression	0,8290	265,59
Polynomial Ridge	0,8196	273,22

Observamos que el modelo de regresión lineal sin regularización, junto con el de regresión lineal con Ridge, son los que tienen un R^2 más elevado.

El modelo que tiene un RMSE más bajo es el de regresión lineal sin regularización.

Los modelos polinómicos no mejoran la predicción y añaden complejidad innecesaria. Ridge ofrece prácticamente los mismos resultados que la regresión lineal simple.

Por tanto, podemos decir que no es necesario regularizar el modelo de regresión lineal (modelo seleccionado) ya que no hay ningún problema de sobreajuste evidente.

Todo el script de Python es subido en un documento aparte, para saber de dónde han salido todos los resultados que se han comentado y evaluado en este documento.